

Analyse et Modélisation de Séries Temporelles : Valeur des Constructions Immobilières et Production Industrielle Alimentaire

Hajer Abdelkefi

2026-04-21

Introduction

Dans le cadre du module **Séries Temporelles**, ce travail porte sur l'analyse et la modélisation de deux séries temporelles économiques à fréquence mensuelle :

- **Série 1** : La valeur des constructions immobilières (*Février 1982 – Janvier 2015, 396 observations*)
- **Série 2** : L'indice de production industrielle du secteur alimentaire *IPG311A2N* (Janvier 1972 – Mars 2024, 627 observations), issu de la base **FRED** de la Réserve Fédérale de St. Louis.

L'objectif est de mener, pour chacune des séries, une analyse complète en **trois phases** :

- **Analyse statistique et graphique**
- **Ajustement de la tendance et de la saisonnalité**
- **Modélisation des résidus par un processus ARIMA**
- **Analyse croisée entre les deux séries**

Plan

1. **Chargement des données et packages**
2. **Série 1 — Valeur des Constructions Immobilières**
 - Phase 1 : Analyse statistique et graphique
 - Phase 2 : Ajustement de la série
 - Phase 3 : Modélisation ARIMA des résidus
3. **Série 2 — Production Industrielle Alimentaire**
 - Phase 1 : Analyse statistique et graphique
 - Phase 2 : Ajustement de la série
 - Phase 3 : Modélisation ARIMA des résidus
4. **Analyse Croisée (CCF)**
5. **Conclusion**

Chargement des données et packages

Packages utilisés

Les packages suivants sont utilisés tout au long de cette analyse :

```
library(readxl)      # Importation des fichiers Excel
library(tidyverse)    # Manipulation et visualisation des données
library(forecast)     # Modélisation ARIMA et prévisions
library(tseries)      # Tests de stationnarité (ADF, KPSS)
library(zoo)          # Gestion des séries temporelles irrégulières
library(xts)          # Visualisation avancée
library(gridExtra)     # Mise en page de plusieurs graphiques
library(knitr)         # Tableaux formatés dans le document
```

Importation des données

Série 1 — Valeur des Constructions Immobilières

```
serie1_raw = read_excel("value of real estate constructions.xlsx",
                        col_names = c("date", "valeur"),
                        skip      = 1)

serie1_raw$date = as.Date(serie1_raw$date)
serie1_raw$valeur = as.numeric(serie1_raw$valeur)

# Objet ts
serie1_ts = ts(serie1_raw$valeur, start = c(1982, 1), end = c(2015, 1),
               frequency = 12)

# Objet zoo
serie1_zoo = zoo(serie1_raw$valeur,
                 order.by = serie1_raw$date)

# Objet xts
serie1_xts <- xts(serie1_raw$valeur,
                 order.by = serie1_raw$date)

print(class(serie1_ts))
```

```
## [1] "ts"
```

```
print(class(serie1_zoo))
```

```
## [1] "zoo"
```

```
print(class(serie1_xts))
```

```
## [1] "xts" "zoo"
```

```
cat("Série 1 - Aperçu :\n")
```

```
## Série 1 - Aperçu :
```

```
cat(" Période      :", format(min(serie1_raw$date), "%B %Y"),  
    "→", format(max(serie1_raw$date), "%B %Y"), "\n")
```

```
## Période      : février 1982 → janvier 2015
```

```
cat(" Observations:", nrow(serie1_raw), "\n")
```

```
## Observations: 396
```

```
cat(" Min / Max    :", min(serie1_raw$valeur),  
    "/", max(serie1_raw$valeur), "\n")
```

```
## Min / Max    : 31.9 / 197.9
```

Série 2 — *Production Industrielle Alimentaire*

```
serie2_raw = read_excel("Industrial Production food S C11.xlsx",  
                        skip      = 10,  
                        col_names = TRUE)
```

```
colnames(serie2_raw) = c("date", "valeur")  
serie2_raw$date      = as.Date(serie2_raw$date)  
serie2_raw$valeur    = as.numeric(serie2_raw$valeur)  
serie2_raw           = na.omit(serie2_raw)
```

```
# Objet ts
```

```
serie2_ts = ts(serie2_raw$valeur,  
               start      = c(1972, 1), end = c(2024, 3),  
               frequency = 12)
```

```
# Objet zoo
```

```
serie2_zoo <- zoo(serie2_raw$valeur,  
                 order.by = serie2_raw$date)
```

```
# Objet xts
```

```
serie2_xts <- xts(serie2_raw$valeur,  
                 order.by = serie2_raw$date)
```

```
print(class(serie2_ts))
```

```
## [1] "ts"
```

```
print(class(serie2_zoo))
```

```
## [1] "zoo"
```

```
print(class(serie2_xts))
```

```
## [1] "xts" "zoo"
```

```
cat("Série 2 - Aperçu :\n")
```

```
## Série 2 - Aperçu :
```

```
cat(" Période      :", format(min(serie2_raw$date), "%B %Y"),  
    "→", format(max(serie2_raw$date), "%B %Y"), "\n")
```

```
## Période      : janvier 1972 → mars 2024
```

```
cat(" Observations:", nrow(serie2_raw), "\n")
```

```
## Observations: 627
```

```
cat(" Min / Max   :", round(min(serie2_raw$valeur), 2),  
    "/", round(max(serie2_raw$valeur), 2), "\n")
```

```
## Min / Max   : 56.73 / 105.37
```

Tableau récapitulatif des deux séries

```
recap <- data.frame(  
  Série      = c("Constructions Immobilières",  
                 "Production Industrielle Alimentaire"),  
  Début      = c("Janvier 1982", "Janvier 1972"),  
  Fin        = c("Janvier 2015", "Mars 2024"),  
  Observations = c(nrow(serie1_raw), nrow(serie2_raw)),  
  Moyenne     = c(round(mean(serie1_raw$valeur), 2),  
                  round(mean(serie2_raw$valeur), 2)),  
  Écart.type  = c(round(sd(serie1_raw$valeur), 2),  
                  round(sd(serie2_raw$valeur), 2))  
)  
  
kable(recap,  
      caption = "\\textbf{Récapitulatif des deux séries temporelles}",  
      booktabs = TRUE,  
      align = "lcccc")
```

Table 1: **Récapitulatif des deux séries temporelles**


Série	Début	Fin	Observations	Moyenne	Écart.type
Constructions Immobilières	Janvier 1982	Janvier 2015	396	112.34	37.58
Production Industrielle Alimentaire	Janvier 1972	Mars 2024	627	86.09	12.96

Série 1 — Valeur des Constructions Immobilières

Phase 1 : Analyse statistique et graphique

Analyse graphique

```
plot(serie1_ts,
     main = "Valeur des Constructions Immobilières (1982-2015)",
     ylab = "Valeur",
     xlab = "Temps")
```



La série ne présente pas une tendance monotone simple. On distingue **plusieurs phases** :


- **1982–1996** : une phase de déclin progressif avec des valeurs passant d'environ 180 à 95, accompagnée d'une saisonnalité régulière.
- **1996–2002** : une phase de reprise marquée, avec des valeurs atteignant un pic autour de 200.
- **2002–2009** : une chute brutale et prolongée, avec les valeurs tombant jusqu'à environ 40, traduisant un **changement structurel majeur** vraisemblablement lié à la crise financière mondiale de 2008.
- **2009–2015** : une phase de légère reprise, sans retrouver les niveaux antérieurs.

On peut écrire $X_t = f(T_t, S_t, E_t)$ où T_t désigne une tendance non linéaire avec changement structurel, S_t la composante saisonnière régulière et E_t les fluctuations irrégulières dont la **variance s'amplifie** au fil du temps, suggérant un possible **modèle multiplicatif**.

Agrégation annuelle

```
serie1_annual = aggregate(serie1_ts, nfrequency = 1, FUN = mean)

plot(serie1_annual,
     main = "Moyenne annuelle - Constructions Immobilières",
     ylab = "Valeur moyenne",
     xlab = "Année")
```




L'agrégation annuelle confirme la présence d'un **changement structurel majeur**. On distingue clairement :

- Une **phase de déclin** entre 1982 et 1988, avec une chute des valeurs jusqu'à environ 85.
- Une **phase de reprise** entre 1988 et 2002, atteignant un pic historique d'environ 170.
- Une **rupture brutale** à partir de 2002–2003, avec une chute drastique jusqu'à environ 50, confirmant le changement structurel déjà observé sur la série brute.
- Une **légère reprise** à partir de 2009, sans retrouver les niveaux d'avant la rupture.

Analyse par boîtes à moustaches


```
boxplot(serie1_ts ~ cycle(serie1_ts),
  main = "Boxplot mensuel - Constructions Immobilières",
  ylab = "Valeur",
  xlab = "Mois",
  names = c("Jan", "Fév", "Mar", "Avr", "Mai", "Jun",
    "Jul", "Aoû", "Sep", "Oct", "Nov", "Déc"))
```

Boxplot mensuel — Constructions Immobilières



```
boxplot(serie1_annual,
  main = "Boxplot annuel - Constructions Immobilières",
  ylab = "Valeur moyenne",
  xlab = "Année")
```

Boxplot annuel — Constructions Immobilières



Le boxplot mensuel révèle une **saisonnalité marquée** : les valeurs les plus élevées sont observées durant les mois de **mars à juillet**, correspondant à la haute saison de l'activité de construction, tandis que les mois de **novembre à février** affichent des valeurs nettement plus faibles.

Le boxplot annuel, quant à lui, présente une **dispersion globale importante** avec une médiane autour de 105 et un écart entre valeur minimale (~50) et maximale (~170), reflet direct du **changement structurel** identifié précédemment.

Analyse statistique descriptive

```
cat("Statistiques descriptives - Série 1 :\n")
```

```
## Statistiques descriptives - Série 1 :
```

```
cat("  Moyenne      :", round(mean(serie1_raw$valeur), 2), "\n")
```

```
##  Moyenne      : 112.34
```

```
cat("  Variance      :", round(var(serie1_raw$valeur), 2), "\n")
```

```
##  Variance      : 1412.04
```



```
cat(" Écart-type      :", round(sd(serie1_raw$valeur), 2), "\n")
```

```
## Écart-type      : 37.58
```

```
cat(" Minimum        :", min(serie1_raw$valeur), "\n")
```

```
## Minimum         : 31.9
```

```
cat(" Maximum        :", max(serie1_raw$valeur), "\n")
```

```
## Maximum         : 197.9
```

```
summary(serie1_ts)
```


```
##   Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
##   31.9   84.5   112.3   112.3   140.4   197.9
```

Les statistiques descriptives confirment cette variabilité : avec une moyenne de **112.34**, un écart-type de **37.58** et un étendue allant de **31.9** à **197.9**, les données présentent une **forte dispersion** autour de la moyenne, traduisant l'instabilité structurelle de la série sur la période d'étude.

Fonction d'autocorrélation (ACF)

```
acf(serie1_ts,
    type = "correlation",
    plot = TRUE,
    main = "ACF - Valeur des Constructions Immobilières")
```

ACF — Valeur des Constructions Immobilières



L'ACF présente une **décroissance lente et progressive** des autocorrélations qui restent toutes **largement au-dessus des bandes de significativité**, confirmant que la série est **non stationnaire** et qu'une tendance forte est présente.


On observe également des **pics périodiques** aux lags multiples de 12 (lag 1.0, 2.0, ...), révélant une **saisonnalité annuelle régulière**. L'absence de valeurs négatives et le maintien des autocorrélations à des niveaux élevés même aux grands lags traduisent la **persistance** de la série, caractéristique d'un processus avec tendance et saisonnalité.

Les trois composantes T_t , S_t et E_t sont donc clairement présentes, ce qui justifie le recours à une **décomposition** dans la phase suivante.

Diagramme retardé (Lag Plot)

```
lag.plot(serie1_ts,
         lags      = 12,
         do.lines = FALSE,
         main      = "Diagramme retardé - Constructions Immobilières")
```

Diagramme retardé — Constructions Immobilières



Le diagramme retardé visualise la dépendance entre les observations X_t et leurs valeurs passées X_{t-k} . On observe :


- **Lags 1 à 3** : une structure linéaire très serrée et bien définie, traduisant une **autocorrélation très forte** entre observations proches dans le temps.
- **Lags 4 à 9** : la structure linéaire reste visible mais le nuage de points s'élargit progressivement, indiquant une **autocorrélation qui s'atténue** avec l'éloignement temporel.
- **Lag 12** : le nuage se resserre à nouveau, révélant un **effet saisonnier annuel** — les observations séparées d'un an restent fortement corrélées.

Décomposition de la série

```
decomp_add = decompose(serie1_ts, type = "additive")
decomp_mult = decompose(serie1_ts, type = "multiplicative")


plot(decomp_add)
```

Decomposition of additive time series



```
plot(decomp_mult)
```


Decomposition of multiplicative time series



ACF des résidus des deux modèles


```
residu_add = decomp_add$random  
residu_mult = decomp_mult$random  
  
acf(residu_add,  
    na.action = na.pass,  
    main      = "ACF résidus - Modèle additif")
```

ACF résidus — Modèle additif



```
acf(residu_mult,  
    na.action = na.pass,  
    main      = "ACF résidus - Modèle multiplicatif")
```

ACF résidus — Modèle multiplicatif



L'ACF des résidus du **modèle additif** présente environ **9 bâtons** dépassant les limites de significativité, indiquant que les résidus ne sont pas un bruit blanc et que le modèle additif ne capture pas correctement toute la structure de la série.

L'ACF des résidus du **modèle multiplicatif** ne présente que **3 bâtons** dépassant les limites de significativité, ce qui traduit des résidus beaucoup plus proches d'un bruit blanc.

Le modèle multiplicatif présente **moins de perte d'information** et constitue donc le modèle adéquat pour cette série. Cependant, les **3 bâtons restants** qui dépassent encore les limites de significativité indiquent une **perte d'information résiduelle**, suggérant que la partie aléatoire ε_t n'est pas encore un bruit blanc pur. Cela justifie l'introduction d'une **variable endogène** — c'est-à-dire les valeurs passées de la série elle-même — pour capturer cette dépendance temporelle restante.

La série s'écrit donc :

$$Y_t = T_t \times S_t \times \varepsilon_t(Y_{t-k})$$

Phase 2 : Ajustement de la série

Modélisation de la tendance par régression polynomiale

```
t = 1:length(serie1_ts)

# Modèle linéaire
model_lin = lm(serie1_ts ~ t)
```

```
# Modèle quadratique
model_quad = lm(serie1_ts ~ t + I(t^2))

summary(model_lin)

##
## Call:
## lm(formula = serie1_ts ~ t)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -76.102 -26.289  -0.292   23.751   91.374
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept) 137.84297     3.47694   39.645 < 2e-16 ***
## t           -0.12835     0.01514   -8.477 4.65e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 34.57 on 395 degrees of freedom
## Multiple R-squared:  0.1539, Adjusted R-squared:  0.1518
## F-statistic: 71.86 on 1 and 395 DF, p-value: 4.655e-16


summary(model_quad)
```

```
##
## Call:
## lm(formula = serie1_ts ~ t + I(t^2))
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -74.131 -24.602   0.912   25.664   84.064
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept) 1.204e+02  5.105e+00  23.589 < 2e-16 ***
## t           1.335e-01  5.924e-02   2.254  0.0247 *
## I(t^2)      -6.580e-04  1.441e-04  -4.565 6.69e-06 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 33.74 on 394 degrees of freedom
## Multiple R-squared:  0.1964, Adjusted R-squared:  0.1923
## F-statistic: 48.15 on 2 and 394 DF, p-value: < 2.2e-16
```

```
temps = as.numeric(time(serie1_ts))


plot(serie1_ts,
     main = "Tendance linéaire",
     ylab = "Valeur", xlab = "Temps")
```

```
lines(temps, as.numeric(fitted(model_lin)),
      col = "red", lwd = 2)
```



```
plot(serie1_ts,
      main = "Tendance quadratique",
      ylab = "Valeur", xlab = "Temps")
lines(temps, as.numeric(fitted(model_quad)),
      col = "blue", lwd = 2)
```


Tendance quadratique



```
cat("Comparaison des modèles de tendance :\n")
```

```
## Comparaison des modèles de tendance :
```

```
cat("  R2 ajusté - Linéaire      :",  
    round(summary(model_lin)$adj.r.squared, 4), "\n")
```

```
##  R2 ajusté - Linéaire      : 0.1518
```

```
cat("  R2 ajusté - Quadratique   :",  
    round(summary(model_quad)$adj.r.squared, 4), "\n")
```

```
##  R2 ajusté - Quadratique   : 0.1923
```

```
cat("  AIC - Linéaire             :", round(AIC(model_lin), 2), "\n")
```

```
##  AIC - Linéaire             : 3943.84
```

```
cat("  AIC - Quadratique          :", round(AIC(model_quad), 2), "\n")
```

```
##  AIC - Quadratique          : 3925.38
```

Les résultats de la comparaison des deux modèles de tendance sont les suivants :

- Le **modèle linéaire** affiche un R^2 ajusté de **0.1518** et un AIC de **3943.84**, indiquant une très faible capacité explicative de la tendance par une droite simple.
- Le **modèle quadratique** affiche un R^2 ajusté de **0.1923** et un AIC de **3925.38**, légèrement supérieur au modèle linéaire.

Le modèle quadratique est **retenu** car il présente un R^2 ajusté plus élevé et un AIC plus faible. Cependant, les deux valeurs de R^2 restent **très faibles**, ce qui s'explique par la présence du **changement structurel majeur** autour de 2002–2008 que ni une droite ni une parabole ne peuvent capturer correctement. Graphiquement, on confirme que la tendance polynomiale ne suit pas fidèlement l'évolution de la série.

La tendance est donc modélisée par :

$$\hat{T}_t = \hat{\alpha}_0 + \hat{\alpha}_1 t + \hat{\alpha}_2 t^2$$

Modèle harmonique complet

```
t = 1:length(serie1_ts)
Mc = matrix(0, length(serie1_ts), 6)
Ms = matrix(0, length(serie1_ts), 6)

for (i in 1:6) {
  Mc[, i] = cos(2 * pi * t * i / 12)
  Ms[, i] = sin(2 * pi * t * i / 12)
}

model_harm = lm(serie1_ts ~ t + I(t^2) + Mc + Ms)
summary(model_harm)
```

```
##
## Call:
## lm(formula = serie1_ts ~ t + I(t^2) + Mc + Ms)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -74.370 -21.154   1.924  19.335  68.919
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  1.203e+02  4.598e+00  26.165  < 2e-16 ***
## t            1.315e-01  5.335e-02   2.465  0.014137 *
## I(t^2)       -6.470e-04  1.298e-04  -4.984  9.47e-07 ***
## Mc1         -1.967e+01  2.155e+00  -9.131  < 2e-16 ***
## Mc2         -7.884e+00  2.157e+00  -3.655  0.000293 ***
## Mc3         -8.286e-01  2.158e+00  -0.384  0.701257
## Mc4          2.146e+00  2.158e+00   0.994  0.320614
## Mc5          1.087e+00  2.167e+00   0.502  0.616024
## Mc6         -5.109e-01  1.704e+00  -0.300  0.764461
## Ms1          4.559e+00  2.157e+00   2.113  0.035246 *
## Ms2         -1.037e+00  2.154e+00  -0.481  0.630492
## Ms3          5.598e-01  2.158e+00   0.259  0.795437
```

```
## Ms4          -1.185e+00  2.155e+00  -0.550 0.582570
## Ms5          -1.728e+00  2.158e+00  -0.801 0.423853
## Ms6          -5.992e+12  3.055e+13  -0.196 0.844613
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 30.37 on 382 degrees of freedom
## Multiple R-squared:  0.3687, Adjusted R-squared:  0.3455
## F-statistic: 15.93 on 14 and 382 DF,  p-value: < 2.2e-16
```

L'analyse des coefficients du modèle complet montre que seuls **Mc1** ($p < 2e - 16$), **Mc2** ($p = 0.0003$) et **Ms1** ($p = 0.035$ *) sont significatifs. Les coefficients **Mc3**, **Mc4**, **Mc5**, **Mc6**, **Ms2**, **Ms3**, **Ms4**, **Ms5**, **Ms6** présentent des p-values largement supérieures à 0.05 et sont donc **non significatifs** — ils seront supprimés du modèle réduit.

Modèle harmonique réduit

```
# Uniquement Mc1, Mc2 et Ms1 sont significatifs
model_harm_red = lm(serie1_ts ~ t + I(t^2) +
                    Mc[, c(1, 2)] + Ms[, 1])
summary(model_harm_red)

##
## Call:
## lm(formula = serie1_ts ~ t + I(t^2) + Mc[, c(1, 2)] + Ms[, 1])
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -73.741 -20.641   1.935  18.983  68.226
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)   1.203e+02  4.559e+00  26.375 < 2e-16 ***
## t             1.320e-01  5.290e-02   2.496 0.012971 *
## I(t^2)        -6.482e-04  1.287e-04  -5.036 7.28e-07 ***
## Mc[, c(1, 2)]1 -1.969e+01  2.137e+00  -9.216 < 2e-16 ***
## Mc[, c(1, 2)]2 -7.898e+00  2.140e+00  -3.691 0.000255 ***
## Ms[, 1]        4.554e+00  2.140e+00   2.128 0.033970 *
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 30.13 on 391 degrees of freedom
## Multiple R-squared:  0.3641, Adjusted R-squared:  0.356
## F-statistic: 44.78 on 5 and 391 DF,  p-value: < 2.2e-16
```

```
cat("Comparaison des modèles harmoniques :\n")
```

```
## Comparaison des modèles harmoniques :
```

```
cat(" R2 ajusté - Modèle complet :",
    round(summary(model_harm)$adj.r.squared, 4), "\n")
```

```
## R2 ajusté - Modèle complet : 0.3455
```

```
cat(" R2 ajusté - Modèle réduit :",
    round(summary(model_harm_red)$adj.r.squared, 4), "\n")
```

```
## R2 ajusté - Modèle réduit : 0.356
```

```
cat(" AIC - Modèle complet :", round(AIC(model_harm), 2), "\n")
```


```
## AIC - Modèle complet : 3853.6
```

```
cat(" AIC - Modèle réduit :", round(AIC(model_harm_red), 2), "\n")
```

```
## AIC - Modèle réduit : 3838.47
```

```
plot(serie1_ts,
     main = "Ajustement harmonique - Constructions Immobilières",
     ylab = "Valeur", xlab = "Temps")
lines(temps, as.numeric(fitted(model_harm_red)),
     col = "red", lwd = 2)
```

Ajustement harmonique — Constructions Immobilières



Dans le modèle réduit, **tous les coefficients retenus sont significatifs** : **Mc1** ($p < 2e - 16$), **Mc2** ($p = 0.0003$) et **Ms1** ($p = 0.034$ *), ainsi que la tendance quadratique **t** et t^2 .

La comparaison finale confirme le choix du modèle réduit :

- R^2 ajusté : **0.356** > **0.3455** ✓
- AIC : **3838.47** < **3853.60** ✓

Le modèle final retenu s'écrit :

$$\hat{Y}_t = 120.3 + 0.132t - 0.000648t^2 - 19.69 \cos \frac{2\pi t}{12} - 7.90 \cos \frac{4\pi t}{12} + 4.55 \sin \frac{2\pi t}{12} + \varepsilon_t$$

Graphiquement, le modèle harmonique réduit capture correctement la **saisonnalité annuelle** de la série. Cependant, le R^2 ajusté de **0.356** reste modéré, confirmant que le **changement structurel** de 2002-2008 ne peut pas être capturé par ce type de modèle.


Phase 3 : Analyse et modélisation des résidus

Extraction et visualisation des résidus

```
residu_harm = ts(residuals(model_harm_red),
                 start = c(1982, 1),
                 frequency = 12)

plot(residu_harm,
     main = "Résidus du modèle harmonique réduit - Série 1",
     ylab = "Résidus",
     xlab = "Temps")
```

Résidus du modèle harmonique réduit — Série 1



Graphiquement, les résidus présentent une **tendance non linéaire** avec de larges oscillations, confirmant qu'ils ne sont pas stationnaires.

Test de stationnarité — Test ADF

```
cat("--- Test ADF sur les résidus ---\n")

## --- Test ADF sur les résidus ---

print(adf.test(residu_harm, alternative = "stationary"))

##
## Augmented Dickey-Fuller Test
##
## data: residu_harm
## Dickey-Fuller = -1.5164, Lag order = 7, p-value = 0.7815
## alternative hypothesis: stationary
```

Le test ADF donne une p-value de **0.7815** $>$ **0.05**, donc on **accepte** H_0 : les résidus sont **non stationnaires**. Une différenciation est nécessaire.

Le test de Augmented Dickey-Fuller teste les hypothèses suivantes :

- H_0 : la série est **non stationnaire**
- H_1 : la série est **stationnaire**

Test de Box-Pierce — Bruit blanc ?

```
cat("--- Test de Box-Pierce sur les résidus ---\n")
```

```
## --- Test de Box-Pierce sur les résidus ---
```

```
print(Box.test(residu_harm, type = "Box-Pierce"))
```

```
##
## Box-Pierce test
##
## data: residu_harm
## X-squared = 346.79, df = 1, p-value < 2.2e-16
```

Le test de Box-Pierce teste les hypothèses suivantes :

- H_0 : $\rho_1 = \rho_2 = \dots = \rho_n = 0$ (*pas d'autocorrélation — bruit blanc*)
- H_1 : il existe au moins un $\rho_i \neq 0$ (*autocorrélation — pas un bruit blanc*)


Le test de Box-Pierce donne une p-value $< 2.2\text{e-}16 < 0.05$, donc on **rejette** H_0 : les résidus ne sont **pas un bruit blanc** — il existe une autocorrélation significative. La modélisation par un processus **ARIMA** est donc justifiée.

Différenciation si nécessaire

```
residu_diff = diff(residu_harm)

plot(residu_diff,
     main = "Résidus différenciés - Série 1",
     ylab = "Résidus",
     xlab = "Temps")
```

Résidus différenciés — Série 1



```
cat("--- Test ADF sur les résidus différenciés ---\n")

## --- Test ADF sur les résidus différenciés ---

print(adf.test(residu_diff, alternative = "stationary"))


##
## Augmented Dickey-Fuller Test
##
## data: residu_diff
## Dickey-Fuller = -9.03, Lag order = 7, p-value = 0.01
## alternative hypothesis: stationary
```

Après différenciation d'ordre 1, la série des résidus présente une forme **plate et stationnaire** graphiquement, sans tendance ni saisonnalité apparente. Le test ADF confirme la stationnarité avec une p-value de **0.01 < 0.05** — on **rejette** H_0 et on conclut que les résidus différenciés sont **stationnaires** ($d = 1$).

Identification des ordres p et q — ACF et PACF


```
acf(residu_diff,
    main = "ACF - Résidus différenciés")
```


ACF — Résidus différenciés



```
pacf(residu_diff,  
      main = "PACF - Résidus différenciés")
```

PACF — Résidus différenciés



L'identification des ordres se fait comme suit :

- **p** (ordre AR) : déterminé par la **PACF** — correspond au nombre de bâtons dépassant l'intervalle de confiance en pointillés.
- **q** (ordre MA) : déterminé par l'**ACF** — correspond au nombre de bâtons significatifs en excluant le lag 0.

Lecture de l'ACF : On observe **1 bâton significatif** au lag 1 (négatif) et un pic au lag 12, suggérant une composante saisonnière. On retient donc $q = 1$ et $Q = 1$.

Lecture de la PACF : On observe **1 bâton significatif** au lag 1 (fortement négatif) et des pics aux lags 12–13. On retient donc $p = 1$ et $d = 1$ (différenciation appliquée).

Le modèle manuel identifié est donc : **ARIMA(1,1,1)(0,1,1)[12]**

Modélisation ARIMA

```
# Modèle automatique
model_auto = auto.arima(residu_harm,
                        seasonal = TRUE,
                        stepwise = FALSE,
                        approximation = FALSE)
summary(model_auto)

## Series: residu_harm
## ARIMA(3,0,0)(1,0,1)[12] with zero mean
##
## Coefficients:
##      ar1      ar2      ar3      sar1      sma1
##      0.4541  0.2868  0.2203  0.8691 -0.5831
## s.e.   0.0521  0.0525  0.0499  0.0615  0.1036
##
## sigma^2 = 72.72:  log likelihood = -1415.84
## AIC=2843.68   AICc=2843.89   BIC=2867.58
##
## Training set error measures:
##              ME      RMSE      MAE      MPE      MAPE      MASE      ACF1
## Training set 0.1777787 8.474012 6.700484 10.03546 85.29328 0.4716587 0.01287984

# Modèle manuel basé sur ACF/PACF
# Les ordres p et q seront ajustés après lecture des graphiques
model_manuel = Arima(residu_harm,
                     order = c(1, 1, 1),
                     seasonal = c(0, 1, 1))
summary(model_manuel)

## Series: residu_harm
## ARIMA(1,1,1)(0,1,1)[12]
```

```
##
## Coefficients:
##          ar1          ma1          sma1
##      -0.1131  -0.4035  -0.7358
## s.e.    0.0938   0.0835   0.0459
##
## sigma^2 = 75.31: log likelihood = -1377.94
## AIC=2763.88  AICc=2763.98  BIC=2779.68
##
## Training set error measures:
##              ME      RMSE      MAE      MPE      MAPE      MASE
## Training set 0.1396136 8.501565 6.59848 1.803218 89.44203 0.4644785
##              ACF1
## Training set -0.004026994
```

```
cat("Comparaison des modèles ARIMA :\n")
```

```
## Comparaison des modèles ARIMA :
```

```
cat("  AIC - auto.arima :", round(AIC(model_auto), 2), "\n")
```

```
##  AIC - auto.arima : 2843.68
```

```
cat("  AIC - manuel      :", round(AIC(model_manuel), 2), "\n")
```

```
##  AIC - manuel      : 2763.88
```

```
cat("  BIC - auto.arima :", round(BIC(model_auto), 2), "\n")
```

```
##  BIC - auto.arima : 2867.58
```

```
cat("  BIC - manuel      :", round(BIC(model_manuel), 2), "\n")
```

```
##  BIC - manuel      : 2779.68
```

La comparaison des deux modèles candidats donne :

- **auto.arima** : ARIMA(3,0,0)(1,0,1)[12] — AIC = **2843.68**, BIC = **2867.58**
- **Modèle manuel** : ARIMA(1,1,1)(0,1,1)[12] — AIC = **2763.88**, BIC = **2779.68**

Le **modèle manuel ARIMA(1,1,1)(0,1,1)[12]** est retenu car il présente un **AIC** et **BIC** inférieurs sur les deux critères :

- AIC : **2763.88** < **2843.68** ✓
- BIC : **2779.68** < **2867.58** ✓


La série des résidus suit donc le modèle :

$$\varepsilon_t \sim \text{ARIMA}(1, 1, 1)(0, 1, 1)_{12}$$

Ce modèle capture à la fois la **dépendance temporelle** à court terme (partie AR et MA d'ordre 1) et la **structure saisonnière** annuelle (partie MA saisonnière d'ordre 1 avec différenciation saisonnière).


Diagnostic du modèle retenu

```
checkresiduals(model_manuel)
```



```
##  
##  Ljung-Box test  
##  
## data:  Residuals from ARIMA(1,1,1)(0,1,1)[12]  
## Q* = 27.266, df = 21, p-value = 0.1622  
##  
## Model df: 3.    Total lags used: 24
```

```
par(mfrow = c(1, 2))  
  
hist(residuals(model_auto),  
     main = "Histogramme des résidus",  
     xlab = "Résidus",  
     col = "lightgray")  
  
qqnorm(residuals(model_auto),  
       main = "Q-Q Plot des résidus")  
qqline(residuals(model_auto), col = "red")
```



```
par(mfrow = c(1, 1))
```

Diagnostic du modèle retenu — ARIMA(1,1,1)(0,1,1)[12] :

Graphique des résidus : Les résidus oscillent autour de zéro sans tendance ni saisonnalité apparente, confirmant la **stationnarité** du modèle retenu.

ACF des résidus : La quasi-totalité des bâtons se situent **dans les bandes de confiance**, indiquant l'absence d'autocorrélation résiduelle significative.

Test de Ljung-Box : La p-value de **0.1622 > 0.05** — on **accepte** H_0 : les résidus sont assimilables à un **bruit blanc**. Le modèle est donc bien spécifié.

Histogramme : La distribution des résidus est **approximativement symétrique** et centrée autour de zéro, suggérant une distribution proche de la normale malgré une légère asymétrie à gauche.


Q-Q Plot : Les points suivent **fidèlement la droite rouge** sur la majorité de la plage, confirmant la **normalité des résidus**, avec de légères déviations aux extrêmes dues aux valeurs aberrantes liées au changement structurel.

Le modèle **ARIMA(1,1,1)(0,1,1)[12]** est donc **validé**.

Prévisions sur 12 mois

```
prevision = forecast(model_auto, h = 12)
```

```
autoplot(prevision) +
  ggtitle("Prévisions sur 12 mois - Constructions Immobilières") +
  xlab("Temps") +
  ylab("Valeur")
```



```
print(prevision)
```

##	Point	Forecast	Lo 80	Hi 80	Lo 95	Hi 95
## Feb 2015	36.18866	25.25974	47.11758	19.474314	52.90301	
## Mar 2015	36.11667	24.11355	48.11980	17.759477	54.47387	
## Apr 2015	31.33200	18.17472	44.48929	11.209670	51.45434	
## May 2015	37.27718	22.69884	51.85553	14.981526	59.57284	
## Jun 2015	39.16258	23.58478	54.74039	15.338382	62.98678	
## Jul 2015	32.76627	16.25239	49.28015	7.510470	58.02208	
## Aug 2015	33.98234	16.59344	51.37123	7.388321	60.57635	
## Sep 2015	40.59182	22.42628	58.75735	12.810026	68.37361	
## Oct 2015	40.21606	21.33300	59.09912	11.336915	69.09521	
## Nov 2015	42.13186	22.58560	61.67812	12.238432	72.02528	
## Dec 2015	46.37627	26.21812	66.53442	15.547035	77.20550	
## Jan 2016	42.65298	21.92609	63.37986	10.953943	74.35201	


Les prévisions sur 12 mois (Février 2015 — Janvier 2016) indiquent une **légère tendance à la hausse** des résidus, avec des valeurs comprises entre **31.3** et **46.4**. Les intervalles de confiance à **80%** et **95%** s'élargissent progressivement avec l'horizon de prévision, traduisant une **incertitude croissante**, ce qui est cohérent avec le comportement habituel des modèles ARIMA.

Série 2 — Production Industrielle Alimentaire

Phase 1 : Analyse statistique et graphique

Analyse graphique

```
plot(serie2_ts,  
     main = "Production Industrielle Alimentaire (1972-2024)",  
     ylab = "Valeur",  
     xlab = "Temps")
```



La série présente une **tendance croissante régulière** sur l'ensemble de la période 1972–2024, passant d'environ **58** à **105**. Contrairement à la Série 1, **aucun changement structurel majeur** n'est observé — la croissance est continue et progressive.


On distingue clairement :

- T_t : une **tendance croissante** quasi-linéaire sur toute la période, avec un léger ralentissement à partir de 2000.
- S_t : une **saisonnalité régulière** visible par les oscillations périodiques répétées d'une année sur l'autre.
- E_t : des **fluctuations aléatoires** d'amplitude relativement **constante** autour de la tendance.

Agrégation annuelle

```
serie2_annual = aggregate(serie2_ts, nfrequency = 1, FUN = mean)

plot(serie2_annual,
     main = "Moyenne annuelle - Production Industrielle Alimentaires",
     ylab = "Valeur moyenne",
     xlab = "Année")
```




L'agrégation annuelle confirme une **tendance croissante régulière et continue** sur toute la période 1972–2024, passant d'environ **60** à **102**. Contrairement à la Série 1, **aucun changement structurel** n'est observé — la croissance est stable et progressive, avec un léger **ralentissement entre 2005 et 2010** avant de reprendre.

Analyse par boîtes à moustaches


```
boxplot(serie2_ts ~ cycle(serie2_ts),
       main = "Boxplot mensuel - Production Industrielle Alimentaires",
       ylab = "Valeur",
       xlab = "Mois",
       names = c("Jan", "Fév", "Mar", "Avr", "Mai", "Jun",
                  "Jul", "Aoû", "Sep", "Oct", "Nov", "Déc"))
```


Boxplot mensuel — Production Industrielle Alimentaire



```
boxplot(serie1_annual,  
  main = "Boxplot annuel - Production Industrielle Alimentaires",  
  ylab = "Valeur moyenne",  
  xlab = "Année")
```

Boxplot annuel — Production Industrielle Alimentaire



Le boxplot mensuel montre des médianes **relativement proches** entre les mois, oscillant entre 88 et 93, ce qui indique une **saisonnalité modérée**. Les mois de **juillet à octobre** présentent des valeurs légèrement plus élevées, tandis que **janvier et mars** affichent les valeurs les plus basses. Le boxplot annuel présente une **large dispersion** avec une médiane autour de **105**, reflet de la forte évolution de la série sur 52 ans. L'asymétrie vers le bas traduit la longue période de faibles valeurs au début de la série.

Analyse statistique descriptive

```
cat("Statistiques descriptives - Série 2 :\n")

## Statistiques descriptives - Série 2 :

cat("  Moyenne      :", round(mean(serie2_raw$valeur), 2), "\n")

##  Moyenne      : 86.09

cat("  Variance      :", round(var(serie2_raw$valeur), 2), "\n")

##  Variance      : 167.98

cat("  Écart-type     :", round(sd(serie2_raw$valeur), 2), "\n")

##  Écart-type     : 12.96

cat("  Minimum        :", min(serie2_raw$valeur), "\n")

##  Minimum        : 56.7317

cat("  Maximum        :", max(serie2_raw$valeur), "\n")

##  Maximum        : 105.3684

summary(serie2_ts)


##    Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
##   56.73   75.47   90.72   86.09   96.69  105.37
```

Les statistiques descriptives montrent une **moyenne de 86.09** avec un écart-type de **12.96**, une étendue allant de **56.73 à 105.37**. Comparée à la Série 1, la dispersion est **beaucoup plus faible** (écart-type 12.96 vs 37.58), ce qui reflète l'évolution **progressive et stable** de la production industrielle alimentaire sans rupture structurelle majeure.

Fonction d'autocorrélation (ACF)

```
acf(serie2_ts,
    type = "correlation",
    plot = TRUE,
    main = "ACF - Production Industrielle Alimentaires")
```

ACF — Production Industrielle Alimentaires




L'ACF présente une **décroissance extrêmement lente** des autocorrélations qui restent **toutes très élevées** (proches de 1.0) et largement au-dessus des bandes de significativité sur tous les lags. Cela confirme que la série est **fortement non stationnaire** avec une **tendance persistante** très marquée. On n'observe pas de pics périodiques nets, ce qui suggère que la **saisonnalité est masquée par la tendance dominante**. Les trois composantes T_t , S_t et E_t sont présentes, avec une tendance particulièrement dominante.

Diagramme retardé (Lag Plot)

```
lag.plot(serie2_ts,
    lags = 12,
    do.lines = FALSE,
    main = "Diagramme retardé - Production Industrielle Alimentaires")
```

Diagramme retardé — Production Industrielle Alimentaires



Le diagramme retardé présente une **structure linéaire extrêmement serrée et bien définie pour tous les lags** de 1 à 12, bien plus prononcée que pour la Série 1. Cela traduit une **autocorrélation très forte et persistante** sur l'ensemble des retards, caractéristique d'une série avec une **tendance déterministe forte**.


- **Lags 1 à 12** : nuages de points quasi-linéaires et très serrés, indiquant que chaque observation est **très fortement corrélée** à ses valeurs passées.
- La structure ne s'élargit **pratiquement pas** d'un lag à l'autre, contrairement à la Série 1 — signe d'une tendance dominante et stable.

Décomposition de la série

```
decomp_add2 = decompose(serie2_ts, type = "additive")
decomp_mult2 = decompose(serie2_ts, type = "multiplicative")


plot(decomp_add2)
```

Decomposition of additive time series



```
plot(decomp_mult2)
```

Decomposition of multiplicative time series




ACF des résidus des deux modèles

```
residu_add2 = decomp_add2$random  
residu_mult2 = decomp_mult2$random
```


```
acf(residu_add2,  
    na.action = na.pass,  
    main      = "ACF résidus - Modèle additif")
```

ACF résidus — Modèle additif



```
acf(residu_mult2,  
    na.action = na.pass,  
    main      = "ACF résidus - Modèle multiplicatif")
```

ACF résidus — Modèle multiplicatif



L'ACF des résidus du **modèle additif** présente environ **8 bâtons** dépassant les limites de significativité, indiquant une perte d'information résiduelle non négligeable. L'ACF des résidus du **modèle multiplicatif** présente également environ **8 bâtons** dépassant les limites de significativité — les deux modèles sont donc **comparables** en termes de résidus.

Cependant, compte tenu de l'analyse graphique qui montre une **amplitude des variations saisonnières constante** autour de la tendance (les deux droites enveloppantes sont quasi-parallèles), le **modèle additif** est retenu :

$$Y_t = T_t + S_t + \varepsilon_t$$

où T_t désigne la tendance croissante régulière, S_t la composante saisonnière d'amplitude constante, et $\varepsilon_t(Y_{t-k})$ la composante aléatoire dépendant des valeurs passées de la série.

Phase 2 : Ajustement de la série

Modélisation de la tendance par régression polynomiale

```
t = 1:length(serie2_ts)

# Modèle linéaire
model_lin2 = lm(serie2_ts ~ t)

# Modèle quadratique
model_quad2 = lm(serie2_ts ~ t + I(t^2))
```

```
summary(model_lin2)
```

```
##
## Call:
## lm(formula = serie2_ts ~ t)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -11.9031  -3.2753  -0.2822   2.7337  11.7470
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  6.484e+01  3.366e-01  192.66  <2e-16 ***
## t            6.768e-02  9.286e-04   72.88  <2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 4.209 on 625 degrees of freedom
## Multiple R-squared:  0.8947, Adjusted R-squared:  0.8946
## F-statistic: 5312 on 1 and 625 DF, p-value: < 2.2e-16
```


```
summary(model_quad2)
```

```
##
## Call:
## lm(formula = serie2_ts ~ t + I(t^2))
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -7.8501  -2.0509  -0.1142   2.1675   8.2563
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  5.782e+01  3.383e-01  170.88  <2e-16 ***
## t            1.347e-01  2.488e-03   54.12  <2e-16 ***
## I(t^2)       -1.067e-04  3.837e-06  -27.80  <2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 2.815 on 624 degrees of freedom
## Multiple R-squared:  0.953, Adjusted R-squared:  0.9528
## F-statistic: 6323 on 2 and 624 DF, p-value: < 2.2e-16
```

```
temps2 = as.numeric(time(serie2_ts))


plot(serie2_ts,
     main = "Tendance linéaire",
     ylab = "Valeur", xlab = "Temps")
lines(temps2, as.numeric(fitted(model_lin2)),
     col = "red", lwd = 2)
```


Tendance linéaire



```
plot(serie2_ts,  
     main = "Tendance quadratique",  
     ylab = "Valeur", xlab = "Temps")  
lines(temps2, as.numeric(fitted(model_quad2)),  
      col = "blue", lwd = 2)
```

Tendance quadratique



Modèle linéaire : La droite rouge suit **fidèlement la tendance globale** de la série sur toute la période, avec un R^2 ajusté de **0.8946** — ce qui signifie que le temps explique **89.46%** de la variance de la série. Tous les coefficients sont hautement significatifs ($p < 2e - 16$ ***).

Modèle quadratique : La courbe bleue s'ajuste encore mieux à la série, capturant le **ralentissement de la croissance** à partir de 2000. Le R^2 ajusté atteint **0.9528** et l'AIC est réduit à **3082.18**.

```
cat("Comparaison des modèles de tendance :\n")
```

```
## Comparaison des modèles de tendance :
```

```
cat("  R2 ajusté - Linéaire    :",  
    round(summary(model_lin2)$adj.r.squared, 4), "\n")
```

```
##  R2 ajusté - Linéaire      : 0.8946
```

```
cat("  R2 ajusté - Quadratique :",  
    round(summary(model_quad2)$adj.r.squared, 4), "\n")
```

```
##  R2 ajusté - Quadratique   : 0.9528
```

```
cat("  AIC - Linéaire           :", round(AIC(model_lin2), 2), "\n")
```

```
##  AIC - Linéaire            : 3585.51
```

```
cat("  AIC - Quadratique      :", round(AIC(model_quad2), 2), "\n")
```

```
##  AIC - Quadratique      : 3082.18
```

La comparaison des deux modèles donne :

- R^2 ajusté : **0.9528** > **0.8946** ✓
- AIC : **3082.18** < **3585.51** ✓

Le **modèle quadratique est retenu**. Contrairement à la Série 1 où les R^2 étaient très faibles (~0.19), ici le modèle quadratique explique **95.28%** de la variance, traduisant une tendance **bien capturée par une parabole**. La tendance s'écrit :

$$\hat{T}_t = 57.82 + 0.1347t - 0.0001067t^2$$

Le coefficient négatif de t^2 confirme graphiquement le **ralentissement progressif** de la croissance à partir de 2000.

Modèle harmonique complet

```
t = 1:length(serie2_ts)
Mc = matrix(0, length(serie2_ts), 6)
Ms = matrix(0, length(serie2_ts), 6)

for (i in 1:6) {
  Mc[, i] = cos(2 * pi * t * i / 12)
  Ms[, i] = sin(2 * pi * t * i / 12)
}

model_harm2 = lm(serie2_ts ~ t + I(t^2) + Mc + Ms)
summary(model_harm2)
```

```
##
## Call:
## lm(formula = serie2_ts ~ t + I(t^2) + Mc + Ms)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -5.9662 -1.3040 -0.0244  1.2191  6.1491
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  5.787e+01  2.287e-01 253.015  < 2e-16 ***
## t            1.342e-01  1.682e-03  79.806  < 2e-16 ***
## I(t^2)       -1.060e-04  2.594e-06 -40.877  < 2e-16 ***
## Mc1          -6.486e-01  1.076e-01  -6.031  2.83e-09 ***
## Mc2          -8.691e-01  1.075e-01  -8.087  3.29e-15 ***
```

```
## Mc3          -1.003e+00  1.076e-01  -9.322  < 2e-16 ***
## Mc4           3.130e-01  1.075e-01   2.912  0.00372 **
## Mc5          -7.356e-01  1.076e-01  -6.835  1.98e-11 ***
## Mc6           4.650e-01  8.299e-02   5.603  3.19e-08 ***
## Ms1          -2.159e+00  1.074e-01 -20.102  < 2e-16 ***
## Ms2          -5.579e-01  1.075e-01  -5.191  2.85e-07 ***
## Ms3           1.394e-01  1.075e-01   1.297  0.19514
## Ms4          -4.959e-01  1.075e-01  -4.614  4.81e-06 ***
## Ms5           5.152e-01  1.074e-01   4.797  2.02e-06 ***
## Ms6           7.217e+11  8.940e+11   0.807  0.41984
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 1.903 on 612 degrees of freedom
## Multiple R-squared:  0.9789, Adjusted R-squared:  0.9784
## F-statistic: 2031 on 14 and 612 DF,  p-value: < 2.2e-16
```

L'analyse des coefficients du modèle complet révèle que **Ms3** ($p = 0.195$) et **Ms6** ($p = 0.420$) sont **non significatifs** — ils seront supprimés. Tous les autres coefficients sont significatifs. Le modèle présente déjà un excellent R^2 ajusté de **0.9784**.

Modèle harmonique réduit

```
# Ms3 et Ms6 non significatifs → supprimés
model_harm_red2 = lm(serie2_ts ~ t + I(t^2) +
                     Mc[, 1:6] +
                     Ms[, c(1, 2, 4, 5)])
summary(model_harm_red2)

##
## Call:
## lm(formula = serie2_ts ~ t + I(t^2) + Mc[, 1:6] + Ms[, c(1, 2,
##      4, 5)])
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -6.0220 -1.3093  0.0071  1.1612  6.0036
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)    5.787e+01  2.288e-01 252.932  < 2e-16 ***
## t              1.343e-01  1.683e-03  79.788  < 2e-16 ***
## I(t^2)        -1.061e-04  2.595e-06 -40.876  < 2e-16 ***
## Mc[, 1:6]1    -6.485e-01  1.076e-01  -6.027  2.88e-09 ***
## Mc[, 1:6]2    -8.694e-01  1.075e-01  -8.087  3.28e-15 ***
## Mc[, 1:6]3    -1.004e+00  1.076e-01  -9.327  < 2e-16 ***
## Mc[, 1:6]4     3.109e-01  1.075e-01   2.892  0.00397 **
## Mc[, 1:6]5    -7.389e-01  1.076e-01  -6.868  1.60e-11 ***
## Mc[, 1:6]6     4.381e-01  7.602e-02   5.763  1.31e-08 ***
## Ms[, c(1, 2, 4, 5)]1 -2.158e+00  1.074e-01 -20.090  < 2e-16 ***
## Ms[, c(1, 2, 4, 5)]2 -5.577e-01  1.075e-01  -5.188  2.89e-07 ***
```

```
## Ms[, c(1, 2, 4, 5)]3 -4.946e-01  1.075e-01  -4.600 5.13e-06 ***
## Ms[, c(1, 2, 4, 5)]4  5.143e-01  1.074e-01   4.788 2.11e-06 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 1.903 on 614 degrees of freedom
## Multiple R-squared:  0.9788, Adjusted R-squared:  0.9784
## F-statistic: 2368 on 12 and 614 DF,  p-value: < 2.2e-16
```

```
cat("Comparaison des modèles harmoniques :\n")
```

```
## Comparaison des modèles harmoniques :
```

```
cat("  R² ajusté - Modèle complet :",
    round(summary(model_harm2)$adj.r.squared, 4), "\n")
```

```
##  R² ajusté - Modèle complet : 0.9784
```

```
cat("  R² ajusté - Modèle réduit :",
    round(summary(model_harm_red2)$adj.r.squared, 4), "\n")
```

```
##  R² ajusté - Modèle réduit : 0.9784
```

```
cat("  AIC - Modèle complet      :", round(AIC(model_harm2), 2), "\n")
```


```
##  AIC - Modèle complet      : 2602.85
```

```
cat("  AIC - Modèle réduit       :", round(AIC(model_harm_red2), 2), "\n")
```

```
##  AIC - Modèle réduit       : 2601.33
```

```
plot(serie2_ts,
     main = "Ajustement harmonique - Production Industrielle Alimentaires ",
     ylab = "Valeur", xlab = "Temps")
lines(temps2, as.numeric(fitted(model_harm_red2)),
     col = "red", lwd = 2)
```

Ajustement harmonique — Production Industrielle Alimentaires



Dans le modèle réduit, **tous les coefficients retenus sont significatifs** après suppression de **Ms3** et **Ms6**.

La comparaison finale confirme le choix du modèle réduit :

- R^2 ajusté : **0.9784 = 0.9784** — identique, donc le modèle réduit est **aussi performant** avec moins de paramètres ✓
- AIC : **2601.33 < 2602.85** ✓

Le **modèle réduit est retenu** par principe de parcimonie. Le modèle final s'écrit :

$$\hat{Y}_t = 57.87 + 0.1342t - 0.000106t^2 + \sum_{k=1}^6 \hat{\beta}_{1k} \cos \frac{2\pi kt}{12} + \sum_{\substack{k=1 \\ k \neq 3,6}}^5 \hat{\beta}_{2k} \sin \frac{2\pi kt}{12} + \varepsilon_t$$

Graphiquement, le modèle harmonique réduit s'ajuste **très fidèlement** à la série — la courbe rouge suit parfaitement les oscillations saisonnières et la tendance quadratique sur l'ensemble de la période 1972–2024. Le R^2 ajusté de **0.9784** confirme que le modèle explique **97.84%** de la variance totale, ce qui est nettement supérieur à la Série 1 (35.6%). Les résidus ε_t seront analysés en **Phase 3**.


Phase 3 : Analyse et modélisation des résidus

Extraction et visualisation des résidus

```
residu_harm2 = ts(residuals(model_harm_red2),
                  start = c(1972, 1),
                  frequency = 12)

plot(residu_harm2,
     main = "Résidus du modèle harmonique réduit - Série 2",
     ylab = "Résidus",
     xlab = "Temps")
```

Résidus du modèle harmonique réduit — Série 2



Graphiquement, les résidus présentent des **ondulations lentes** autour de zéro sans tendance nette, suggérant une stationnarité limitée.

Test de stationnarité — Test ADF

```
cat("--- Test ADF sur les résidus ---\n")
```

```
## --- Test ADF sur les résidus ---
```

```
print(adf.test(residu_harm2, alternative = "stationary"))
```

```
##
```

```
## Augmented Dickey-Fuller Test
##
## data: residu_harm2
## Dickey-Fuller = -3.7909, Lag order = 8, p-value = 0.01946
## alternative hypothesis: stationary
```

Le test ADF donne une p-value de **0.0195** < **0.05**, donc on **rejette** H_0 : les résidus sont **stationnaires** — **aucune différenciation n'est nécessaire** ($d = 0$).

Le test de Augmented Dickey-Fuller teste les hypothèses suivantes :

- H_0 : la série est **non stationnaire**
- H_1 : la série est **stationnaire**

Test de Box-Pierce — Bruit blanc ?

```
cat("--- Test de Box-Pierce sur les résidus ---\n")
```

```
## --- Test de Box-Pierce sur les résidus ---
```

```
print(Box.test(residu_harm2, type = "Box-Pierce"))
```

```
##
## Box-Pierce test
##
## data: residu_harm2
## X-squared = 421.7, df = 1, p-value < 2.2e-16
```


Le test de Box-Pierce teste les hypothèses suivantes :

- H_0 : $\rho_1 = \rho_2 = \dots = \rho_n = 0$ (*pas d'autocorrélation — bruit blanc*)
- H_1 : il existe au moins un $\rho_i \neq 0$ (*autocorrélation — pas un bruit blanc*)

Le test de Box-Pierce donne une p-value < **2.2e-16** < **0.05**, donc on **rejette** H_0 : les résidus ne sont **pas un bruit blanc**. La modélisation par un processus **ARIMA** est donc justifiée.


```
acf(residu_harm2,
    main = "ACF - Résidus série 2")
```


ACF — Résidus série 2



```
pacf(residu_harm2,  
      main = "PACF - Résidus série 2")
```

PACF — Résidus série 2



Lecture de l'ACF : Décroissance lente et progressive des autocorrélations, toutes positives et significatives — comportement typique d'un processus **AR** dominant. On retient $q = 1$.

Lecture de la PACF : Un seul bâton **très significatif** au lag 1 (~ 0.8) suivi d'une coupure nette, caractéristique d'un processus **AR(1)**. On retient $p = 1$.

Le modèle candidat manuel identifié est : **ARIMA(1,0,1)**

Modélisation ARIMA

```
# Modèle automatique
model_auto2 = auto.arima(residu_harm2,
                          seasonal = TRUE,
                          stepwise = FALSE,
                          approximation = FALSE)
summary(model_auto2)

## Series: residu_harm2
## ARIMA(1,0,1)(1,0,1)[12] with zero mean
##
## Coefficients:
##          ar1      ma1      sar1      sma1
##      0.9047 -0.3145  0.8215 -0.5820
## s.e.  0.0214  0.0483  0.0702  0.0996
##
## sigma^2 = 0.9581:  log likelihood = -876.32
## AIC=1762.64  AICc=1762.74  BIC=1784.84
##
## Training set error measures:
##              ME      RMSE      MAE      MPE      MAPE      MASE
## Training set -0.006327451 0.9756817 0.7219999 119.3856 238.1507 0.500702
##              ACF1
## Training set 0.004976103
```

```
# Modèle manuel basé sur ACF/PACF
# p=1 (PACF lag 1), d=0 (stationnaire), q=1 (ACF)
# P=1, D=0, Q=1 : pics saisonniers détectés aux lags 12
model_manuel2 = Arima(residu_harm2,
                      order = c(1, 0, 1),
                      seasonal = c(1, 0, 1))
summary(model_manuel2)
```

```
## Series: residu_harm2
## ARIMA(1,0,1)(1,0,1)[12] with non-zero mean
##
## Coefficients:
##          ar1      ma1      sar1      sma1      mean
##      0.9047 -0.3146  0.8217 -0.5824  0.1146
## s.e.  0.0214  0.0483  0.0700  0.0993  0.6123
##
```

```
## sigma^2 = 0.9595: log likelihood = -876.3
## AIC=1764.6   AICc=1764.73   BIC=1791.24
##
## Training set error measures:
##           ME      RMSE      MAE      MPE      MAPE      MASE
## Training set -0.01333542 0.9756522 0.7219607 118.7235 237.5214 0.5006749
##           ACF1
## Training set 0.005146471
```

```
cat("Comparaison des modèles ARIMA :\n")
```

```
## Comparaison des modèles ARIMA :
```

```
cat("  AIC - auto.arima :", round(AIC(model_auto2), 2), "\n")
```

```
##   AIC - auto.arima : 1762.64
```

```
cat("  AIC - manuel      :", round(AIC(model_manuel2), 2), "\n")
```

```
##   AIC - manuel      : 1764.6
```

```
cat("  BIC - auto.arima :", round(BIC(model_auto2), 2), "\n")
```

```
##   BIC - auto.arima : 1784.84
```

```
cat("  BIC - manuel      :", round(BIC(model_manuel2), 2), "\n")
```

```
##   BIC - manuel      : 1791.24
```

La comparaison des deux modèles candidats donne :

- **auto.arima** : ARIMA(1,0,1)(1,0,1)[12] *with zero mean* — AIC = **1762.64**, BIC = **1784.84**
- **Modèle manuel** : ARIMA(1,0,1)(1,0,1)[12] *with non-zero mean* — AIC = **1764.60**, BIC = **1791.24**

Les deux modèles ont **exactement la même structure** — ce qui confirme que la lecture graphique de l'ACF/PACF était correcte. La seule différence est que le modèle manuel estime une **moyenne non nulle** (mean = 0.1146) qui s'avère **non significative** ($p > 0.05$), ce qui explique la légère pénalisation par l'AIC et le BIC.

Le **modèle auto.arima** est **retenu** par principe de parcimonie :

- AIC : **1762.64** < **1764.60** ✓
- BIC : **1784.84** < **1791.24** ✓


La série des résidus suit donc le modèle :

$$\varepsilon_t \sim \text{ARIMA}(1, 0, 1)(1, 0, 1)_{12}$$

Ce modèle capture à la fois la **forte persistance** de la série (ar1 = 0.9047) et la **structure saisonnière annuelle** via les composantes SAR(1) et SMA(1).


Diagnostic du modèle retenu

```
checkresiduals(model_auto2)
```



```
##  
##  Ljung-Box test  
##  
## data:  Residuals from ARIMA(1,0,1)(1,0,1)[12] with zero mean  
## Q* = 21.515, df = 20, p-value = 0.3674  
##  
## Model df: 4.   Total lags used: 24
```

```
par(mfrow = c(1, 2))  
  
hist(residuals(model_auto2),  
     main = "Histogramme des résidus",  
     xlab = "Résidus",  
     col = "lightgray")  
  
qqnorm(residuals(model_auto2),  
       main = "Q-Q Plot des résidus")  
qqline(residuals(model_auto2), col = "red")
```



```
par(mfrow = c(1, 1))
```

Diagnostic du modèle retenu — ARIMA(1,0,1)(1,0,1)[12] :

Graphique des résidus : Les résidus oscillent autour de zéro de façon **stationnaire** sur toute la période 1972–2024, sans tendance ni saisonnalité apparente. On note une **valeur aberrante** vers 2020, vraisemblablement liée à l’impact de la **crise COVID-19** sur la production industrielle alimentaire.

ACF des résidus : La quasi-totalité des bâtons se situent **dans les bandes de confiance**, confirmant l’absence d’autocorrélation résiduelle significative.

Test de Ljung-Box : La p-value de **0.3674 > 0.05** — on **accepte** H_0 : les résidus sont assimilables à un **bruit blanc**. Le modèle est donc bien spécifié.

Histogramme : La distribution est **approximativement normale** et centrée autour de zéro, malgré une légère asymétrie à gauche due à la valeur aberrante de 2020.

Q-Q Plot : Les points suivent **très fidèlement la droite rouge** sur la quasi-totalité de la plage, confirmant la **normalité des résidus**. La déviation en bas à gauche correspond à la valeur aberrante COVID-19 de 2020 — point isolé qui n’affecte pas la qualité globale du modèle.


Le modèle **ARIMA(1,0,1)(1,0,1)[12]** est donc **validé**.

$$\varepsilon_t \sim \text{ARIMA}(1, 0, 1)(1, 0, 1)_{12}$$

Prévisions sur 12 mois

```
prevision2 = forecast(model_auto2, h = 12)

autoplot(prevision2) +
  ggtitle("Prévisions sur 12 mois - Production Industrielle Alimentaires ") +
  xlab("Temps") +
  ylab("Valeur")
```



```
print(prevision2)
```

##	Point Forecast	Lo 80	Hi 80	Lo 95	Hi 95
## Apr 2024	0.5098046	-0.7445895	1.7641987	-1.408626	2.428235
## May 2024	-0.2770870	-1.7336684	1.1794945	-2.504736	1.950562
## Jun 2024	-0.4563646	-2.0595662	1.1468370	-2.908250	1.995521
## Jul 2024	-0.8541322	-2.5680295	0.8597651	-3.475312	1.767047
## Aug 2024	-0.8240265	-2.6234648	0.9754117	-3.576030	1.927977
## Sep 2024	-0.7186056	-2.5851418	1.1479305	-3.573226	2.136015
## Oct 2024	-0.5109775	-2.4306871	1.4087320	-3.446920	2.424965
## Nov 2024	-0.7663846	-2.7285431	1.1957740	-3.767247	2.234478
## Dec 2024	-0.3238129	-2.3200431	1.6724174	-3.376784	2.729158
## Jan 2025	0.4698474	-1.5538428	2.4935376	-2.625120	3.564815
## Feb 2025	1.0012416	-1.0446496	3.0471328	-2.127679	4.130162
## Mar 2025	1.3379992	-0.7258852	3.4018836	-1.818440	4.494438

Les prévisions sur 12 mois (Avril 2024 — Mars 2025) indiquent des valeurs des résidus oscillant autour de **zéro**, comprises entre **-0.85** et **1.34**, ce qui est cohérent avec un processus stationnaire bien modélisé.

Les intervalles de confiance à **80%** et **95%** s'élargissent progressivement avec l'horizon de prévision, traduisant une **incertitude croissante** — comportement attendu pour tout modèle ARIMA.

Graphiquement, les prévisions convergent rapidement vers **zéro** avec des intervalles de confiance qui s'élargissent, ce qui est caractéristique d'un processus **stationnaire** — contrairement à la Série 1 où les prévisions montraient une légère tendance à la hausse due à la différenciation ($d = 1$).

Analyse Croisée (CCF)

Restriction à la période commune

```
# Restriction à la période commune : Fév 1982 → Jan 2015
serie2_common = window(serie2_ts,
                        start = c(1982, 2),
                        end   = c(2015, 1))

residu_harm2_common = window(residu_harm2,
                             start = c(1982, 2),
                             end   = c(2015, 1))

cat("Période commune :\n")
```

```
## Période commune :
```

```
cat("  Série 1 :", length(serie1_ts), "observations\n")
```

```
##   Série 1 : 397 observations
```


```
cat("  Série 2 :", length(serie2_common), "observations\n")
```

```
##   Série 2 : 396 observations
```


Corrélation croisée sur les séries brutes

```
acf(ts.union(serie1_ts, serie2_common),
    na.action = na.pass,
    main = "Corrélogramme croisé - Séries brutes")
```


Corrélogramme croisé — Séries brutes




Corrélogramme croisé — Séries brutes



Corrélogramme croisé — Séries brutes




Corrélogramme croisé — Séries brutes



Corrélation croisée sur les résidus

```
acf(ts.union(residu_harm, residu_harm2_common),
    na.action = na.pass,
    main      = "Corrélogramme croisé - Résidus")
```

Interprétation

Corrélogramme croisé — Séries brutes : Les autocorrélations individuelles des deux séries restent **fortes et positives**, confirmant la non-stationnarité déjà identifiée. La corrélation croisée entre les deux séries montre des valeurs **négatives et significatives**, indiquant que les deux séries évoluent en **sens opposés** sur la période commune 1982–2015 : lorsque la valeur des constructions immobilières augmente, la production industrielle alimentaire tend à diminuer relativement, et vice versa.

Corrélogramme croisé — Résidus : Après élimination des parties déterministes (tendance et saisonnalité), la corrélation croisée entre les résidus des deux modèles devient **quasi nulle et non significative** pour les lags négatifs, indiquant que la **production industrielle alimentaire n’influence pas les constructions immobilières** avec un retard.

Cependant, les résidus de la Série 1 présentent encore une **autocorrélation propre forte**, ce qui confirme la présence d’une **variable endogène** dominante — les valeurs passées de la série elle-même sont plus explicatives qu’une variable exogène.

Modélisation avec variable exogène

La corrélation croisée sur les résidus étant **faible**, l’ajout d’une **variable exogène** ($X_t = \text{Production Industrielle Alimentaire}$) dans le modèle ARIMA de la Série 1 peut néanmoins être testé pour vérifier si elle

apporte une information supplémentaire :

```
# Aligner les deux séries sur exactement la même période
serie1_common = window(serie1_ts,
                        start = c(1982, 2),
                        end   = c(2015, 1))

cat("Vérification des longueurs :\n")
```

```
## Vérification des longueurs :
```

```
cat("  Série 1 :", length(serie1_common), "observations\n")
```

```
##  Série 1 : 396 observations
```

```
cat("  Série 2 :", length(serie2_common), "observations\n")
```

```
##  Série 2 : 396 observations
```

```
model_xreg = Arima(serie1_common,
                   order      = c(1, 1, 1),
                   seasonal    = c(0, 1, 1),
                   xreg        = serie2_common)
summary(model_xreg)
```

```
## Series: serie1_common
## Regression with ARIMA(1,1,1)(0,1,1)[12] errors
##
## Coefficients:
##          ar1          ma1          sma1          xreg
##      -0.1155   -0.3999   -0.7548   -0.7123
## s.e.    0.0954    0.0858    0.0443    0.4736
##
## sigma^2 = 74.23:  log likelihood = -1371.46
## AIC=2752.91  AICc=2753.07  BIC=2772.65
##
## Training set error measures:
##              ME      RMSE      MAE      MPE      MAPE      MASE
## Training set 0.1190741 8.428565 6.538798 0.3299769 6.741502 0.4814855
##              ACF1
## Training set -0.003884843
```

```
cat("\nComparaison avec/sans variable exogène :\n")
```

```
##
## Comparaison avec/sans variable exogène :
```

```
cat("  AIC sans xreg :", round(AIC(model_manuel), 2), "\n")
```

```
##  AIC sans xreg : 2763.88
```

```
cat(" AIC avec xreg :", round(AIC(model_xreg), 2), "\n")
```

```
## AIC avec xreg : 2752.91
```

Les résultats du modèle avec variable exogène donnent :

- Le coefficient **xreg** = **-0.7123** avec un écart-type de **0.4736** — ce coefficient est **non significatif** ($|t| = 0.7123/0.4736 = 1.50 < 1.96$), indiquant que la production industrielle alimentaire n'est pas un prédicteur significatif de la valeur des constructions immobilières.
- Cependant, l'AIC passe de **2763.88** à **2752.91**, soit une **amélioration de 10.97 points**.
- AIC sans xreg : **2763.88**
- AIC avec xreg : **2752.91** ✓

Bien que le coefficient de la variable exogène soit **non significatif individuellement**, la légère amélioration de l'AIC suggère qu'elle apporte une **information marginale** au modèle. Ce résultat confirme que la relation entre les deux séries

Conclusion

Ce travail a porté sur l'analyse et la modélisation de deux séries temporelles économiques mensuelles suivant la méthodologie de **Box-Jenkins** en trois phases.

La **Série 1** (Constructions Immobilières) présente un **changement structurel majeur** lié à la crise de 2008 et suit un **modèle multiplicatif**. Son ajustement harmonique explique **35.6%** de la variance, et ses résidus sont modélisés par **ARIMA(1,1,1)(0,1,1)[12]** :

$$Y_t = T_t \times S_t \times \varepsilon_t, \quad \varepsilon_t \sim \text{ARIMA}(1, 1, 1)(0, 1, 1)_{12}$$

La **Série 2** (Production Industrielle Alimentaire) présente une **tendance croissante régulière** sans rupture et suit un **modèle additif**. Son ajustement harmonique explique **97.84%** de la variance, et ses résidus sont modélisés par **ARIMA(1,0,1)(1,0,1)[12]** :

$$Y_t = T_t + S_t + \varepsilon_t, \quad \varepsilon_t \sim \text{ARIMA}(1, 0, 1)(1, 0, 1)_{12}$$

L'analyse croisée révèle une **relation négative** entre les deux séries brutes qui devient **faible sur les résidus**, confirmant une influence indirecte entre les deux secteurs économiques.